2026 소프트웨어학과 졸업 프로젝트 결과보고서

EFL Sprite

온디바이스 AI 기반 영어 스피킹·라이팅 코치

— TOEFL iBT(2026) 형식 연습, 근거 있는 자동 채점, 교사 협업 첨삭 —

소속	단국대학교 SW융합대학 소프트웨어학과
학번	32210214
성명	곽태훈 (Taehoon Kwack)
개발 기간	2026. 11. 2. – 2026. 11. 17.
저장소	github.com/sonnykwack/efl-sprite
배포	Microsoft Store — apps.microsoft.com/detail/9MZT0SB40M2W (MSIX, 2026. 11. 9. v0.1.0 게시, 11. 12. v0.1.1 업데이트 제출)

요약

영어 말하기·쓰기 연습은 강사의 첨삭 시간에 묶여 있다. 학생은 답안을 낸 뒤 피드백을 며칠씩 기다리고, 2026년 개편된 TOEFL iBT의 새 유형(Listen and Repeat, Take an Interview, Write an Email, Academic Discussion)을 연습하고 채점받을 도구는 거의 없다. 기존 AI 첨삭 서비스는 학생의 글과 목소리를 외부 서버로 보내야 하고, 점수의 근거를 설명하지 못하는 경우가 많다.

본 프로젝트는 **모든 AI 추론을 사용자의 PC 안에서 수행**하는 데스크톱 앱 EFL Sprite를 개발해 Microsoft Store에 배포했다. 음성 인식(Whisper), 채점용 대형 언어 모델(로컬 LLM), 학습자 문법 교정 모델(GECToR)을 하나의 파이프라인으로 묶고, **문법은 문법 모델과 규칙이, 내용과 논리는 LLM이 판단**하도록 역할을 나눴다. 출력 형식은 JSON 스키마로 강제해 모델이 학생 문장을 먼저 인용한 뒤 점수를 내게 했고, 인용 위치 보정·재검증·상한 규칙·측정 언어 지표로 결과를 보정했다. 강사는 AI 첨삭을 검토하고 직접 첨삭할 수 있으며, 문제는 AI로 생성하거나 파일로 공유할 수 있다.

현직 TOEFL 강사(저자)의 블라인드 채점 8건과 비교한 결과 평균 절대 오차 0.44밴드, ±0.5밴드 이내 일치 75%를 보였고, 같은 답안을 반복 채점할 때의 항목 점수 표준편차는 0.94에서 0.00으로 줄었다. 앱은 macOS와 Windows에서 매 변경마다 자동 빌드되며, MSIX 패키지로 Microsoft Store 심사를 통과해 게시되었다.

0.44	75%	0.94→0.00	7/7
교사–AI 평균 절대 오차(밴드)	±0.5밴드 이내 일치 (8건)	반복 채점 표준편차	문법 모델의 의도적 오류 검출

목차

1. 서론 — 배경과 문제 정의
2. 목표와 요구사항
3. 관련 기술과 기존 서비스
4. 시스템 설계
5. 구현
6. 실험과 평가
7. 배포와 품질 관리
8. 개발 과정과 역할 분담
9. 결론과 향후 과제

부록 — 설치 방법, 저장소 구조, 참고 자료

1. 서론 — 배경과 문제 정의

1.1 배경

저자는 영어 학원에서 TOEFL을 가르치고 있다. 읽기·듣기 영역은 정답이 있어 학생이 혼자 반복 연습할 수 있지만, 말하기·쓰기 영역은 답안마다 강사의 첨삭이 필요하다. 강사 한 명이 볼 수 있는 답안 수에는 한계가 있으므로, 학생의 연습량은 곧 강사의 시간에 비례하게 된다.

2026년 1월부터 TOEFL iBT는 시험 형식이 바뀌어 말하기에 *Listen and Repeat*, *Take an Interview*, 쓰기에 *Write an Email*, *Academic Discussion* 유형이 포함되었다. 새 형식에 맞춘 연습·채점 도구는 아직 드물다.

1.2 문제 정의

문제	내용
피드백 병목	답안 1건마다 강사 첨삭이 필요해 피드백이 지연되고 연습량이 제한된다.
새 시험 형식	2026 TOEFL iBT의 새 유형을 실제 형식(타이머, 요구사항)대로 연습할 도구가 부족하다.
클라우드 AI의 한계	학생 데이터를 외부 서버로 보내야 하고, 구독료가 들며, 네트워크가 제한된 학원 컴퓨터실에서 쓰기 어렵다. 점수의 근거를 설명하지 못하는 경우가 많다.
범용 LLM 채점의 불안정성	같은 답안도 실행할 때마다 점수가 달라지고, 맞는 문장을 틀렸다고 하거나 실제 오류를 놓친다(6장 실험에서 확인).

1.3 접근

모든 추론을 PC 안에서 수행하는 데스크톱 앱으로 개인정보와 비용 문제를 해결하고, 채점을 **규칙 · 학습자 문법 모델 · LLM**의 역할 분담 구조로 설계해 정확도와 설명 가능성을 높인다. 강사는 AI 결과를 검토·수정하는 사람으로 루프에 참여한다(human-in-the-loop).

2. 목표와 요구사항

2.1 목표

1. 학생이 TOEFL iBT 2026 형식 4개 유형을 혼자 연습하고 **1–2분 안에 근거 있는 피드백**을 받는다.
2. 답안·녹음·점수가 **기기 밖으로 나가지 않는다.**
3. 강사가 AI 결과를 **검토하고 바로잡을 수 있으며**, 문제를 손쉽게 만들고 배포한다.
4. Mac에서 개발하고 **Windows(Microsoft Store)로 배포**한다.

2.2 기능 요구사항

ID	요구사항	내용

F1	4개 유형 응시	유형별 타이머·자동 제출. 스피킹은 문장 재생(TTS)과 녹음, "다음" 버튼 또는 제한 시간으로 진행
F2	자동 채점	추정 밴드(1.0–6.0), 항목별 0–5점, 항목마다 학생 문장 인용 근거, 한국어 총평
F3	교정 설명	밑줄 클릭 시 고친 표현(단어 단위 비교), 문장별 이유, 문법 원칙, 예문
F4	이메일 요구사항 확인	문제가 요구한 항목을 다룸/부족/빠짐으로 판정하고 근거 문장 표시
F5	언어 지표	분량, 어휘 다양성, 문장 구조, 문법 정확성, 연결어를 측정해 0–5와 개선 팁
F6	스피킹 채점	따라 말하기 단어별 맞음/틀림/빠뜨림, 녹음 다시 듣기, 인터뷰는 전사문 + 유창성 지표로 채점
F7	문제 관리	직접 출제·수정·삭제, 로컬 AI 문제 생성, `.eflsprite` 파일로 내보내기·가져오기(카카오톡·USB 배포)
F8	교사 첨삭	드래그로 구간 선택 → 오류 유형·고친 표현·코멘트, AI 교정 맞음/틀림 검토, 수정된 에세이, 학생 화면에 교사 첨삭 우선 반영
F9	기록·일치도	학생별 기록, 교사 점수 입력, 교사–AI 일치도(MAE, ±0.5 비율, 경향), AI 교정 정확도
F10	온보딩	엔진 확인 → 추천 모델 다운로드 → 예시 문제 → 첫 응시 체크리스트

2.3 비기능 요구사항

항목	기준
개인정보	모델 다운로드 외 네트워크 사용 없음, 분석·광고 없음
일관성	같은 답안 반복 채점 시 항목 점수 표준편차 ≤ 0.5
성능	Apple Silicon 기준 1회 채점 2분 이내
호환성	macOS·Windows 동일 코드, 한글 사용자 폴더 경로에서 동작
신뢰성	답안은 채점 전에 저장(채점 실패 시에도 보존), 모든 대기 작업에 시간 제한과 오류 안내
배포	Microsoft Store 정책 준수(MSIX, 권한 선언, 상표 표기)

3. 관련 기술과 기존 서비스

3.1 기술 선택

영역	선택	이유
앱 프레임워크	Tauri v2 (Rust) + React/TypeScript	Electron 대비 작은 크기, Rust 백엔드에서 프로세스·파일·DB를 안전하게 다룸, macOS·Windows 단일 코드

LLM 추론	llama.cpp (`llama-server`)	GGUF 양자화 모델의 CPU/GPU(Metal, Vulkan) 추론, JSON 스키마 → 문법 제약 디코딩 지원, 병렬 슬롯
채점 모델	Qwen2.5-7B-Instruct (Q4_K_M)	3B·4B 대비 안정적인 판단(6장), 4.5 GB로 일반 노트북에서 실행 가능. 14B는 고정밀 옵션
음성 인식	whisper.cpp (small.en)	오프라인, 영어 전용 모델의 높은 정확도, Metal 가속
문법 교정	GECToR RoBERTa-base (ONNX Runtime)	학습자 영어(BEA, CoNLL)로 학습된 태깅 모델. 범용 LLM보다 학습자 오류에 정밀
저장	SQLite (rusqlite)	단일 파일, 마이그레이션 관리, 외부 서버 불필요

3.2 기존 서비스와의 차별점

	클라우드 AI 첨삭 서비스	EFL Sprite
데이터	서버 전송	기기 안에서만 처리
네트워크·비용	상시 연결, 구독료	모델 다운로드 후 오프라인, 무료
시험 형식	범용 에세이	TOEFL iBT 2026 4개 유형
근거	점수 위주	항목별 학생 문장 인용, 측정 지표, 교정 이유·원칙
문법 교정	LLM 단일 판단	규칙 + 학습자 문법 모델 + LLM, 재검증
교사 역할	없음	교사 첨삭이 AI보다 우선, AI 교정 정확도 측정

4. 시스템 설계

4.1 전체 구조

UI(React)는 모든 백엔드 호출을 `api.ts` 한 곳을 통해 Tauri 명령으로 보낸다. Rust 백엔드는 SQLite, 모델 다운로드, 녹음 파일, 그리고 세 개의 추론 엔진을 관리한다. LLM과 Whisper는 별도 프로세스로 실행하고, GECToR는 ONNX Runtime 동적 라이브러리를 Rust에서 직접 호출한다.

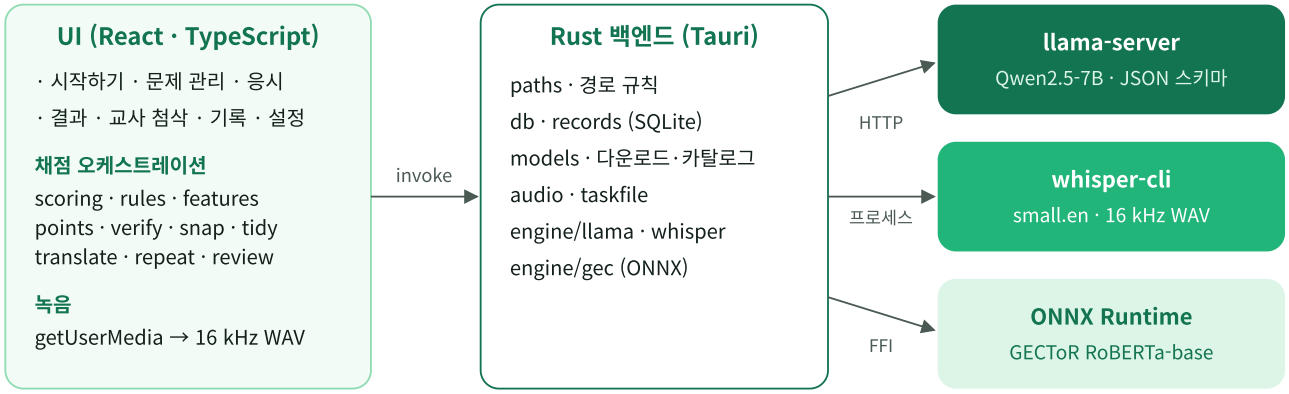


그림 1. 시스템 구성 — UI, Rust 백엔드, 세 추론 엔진

4.2 채점 파이프라인

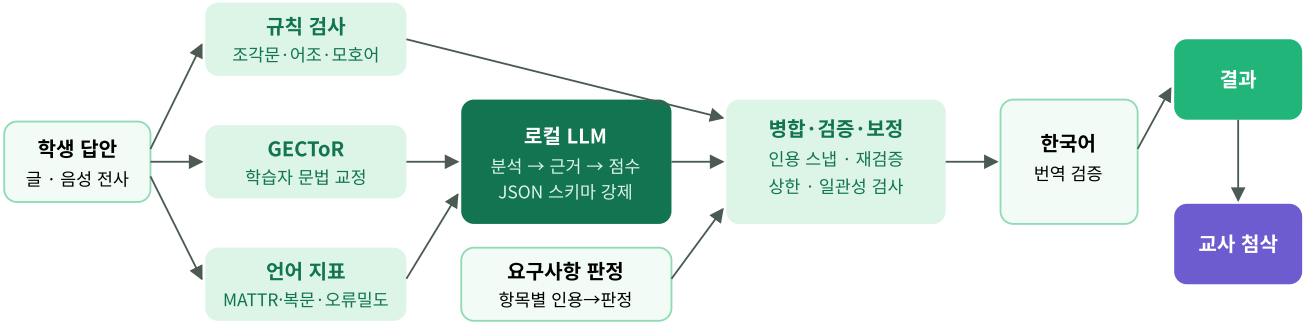


그림 2. 채점 파이프라인 — 문법은 규칙·문법 모델, 내용은 LLM, 결과는 교사가 검토

설계 원칙은 다음과 같다.

- **근거 먼저, 점수는 나중:** 항목별 출력의 키 순서를 `evidence → comment → score`로 고정하고, 직렬화 단계에서도 키 순서를 보존(`preserve_order`)한다. 모델은 학생 문장을 인용해야만 점수를 낼 수 있다.
- **문법 제약 디코딩:** llama-server의 `response_format: json_schema`로 출력 형식을 토큰 단위에서 강제한다. 형식이 깨진 응답이 원천적으로 생기지 않는다.
- **역할 분담(정확도 우선):** 문법 범주(수일치, 관사, 시제, 전치사, 조각문, 철자)는 GECToR와 규칙만 판정한다. LLM은 어휘 선택·어조·무종지문 등만 제안하고, 각 제안은 별도 호출로 재검증한다.
- **측정 가능한 것은 코드로:** 언어 지표를 LLM 입력에 제공하고, LLM의 언어 점수가 지표 평균과 1.5점 이상 다르면 1점 조정한다(ETS e-rater의 특징 기반 접근을 참고).
- **보정:** 보정 앵커(평가 주제와 겹치지 않는 약·중·강 예시), 분량·어조·오류 밀도 상한, 교사 점수로 맞춘 구간별 밴드 환산표.

4.3 데이터 모델

테이블	주요 컬럼	비고
tasks	section, task_type, title, prompt, material, prep_seconds, response_seconds	유형은 수정 불가(채점 기준 보존)

students	name	선택 입력
attempts	task_id, student_id, response_text, audio_path, duration_seconds, teacher_review(JSON)	채점 전에 먼저 저장
evaluations	attempt_id, model_id, rubric_json, total_score(밴드), teacher_score, latency_ms	재채점 시 새 행 추가(이력 보존)

스키마 버전은 `PRAGMA user_version`으로 관리하며(v1→v3), 마이그레이션 중 외래 키 무결성을 검사한다.

5. 구현

소스 코드는 TypeScript/TSX 약 10,400줄(46개 파일), Rust 약 2,600줄(12개 파일)이며, Git 커밋 71개(2026-11-12 기준)로 관리했다. 화면 코드는 초기 버전 이후 저자가 참조 작성하였다(8장).

5.1 채점 결과와 교정 설명

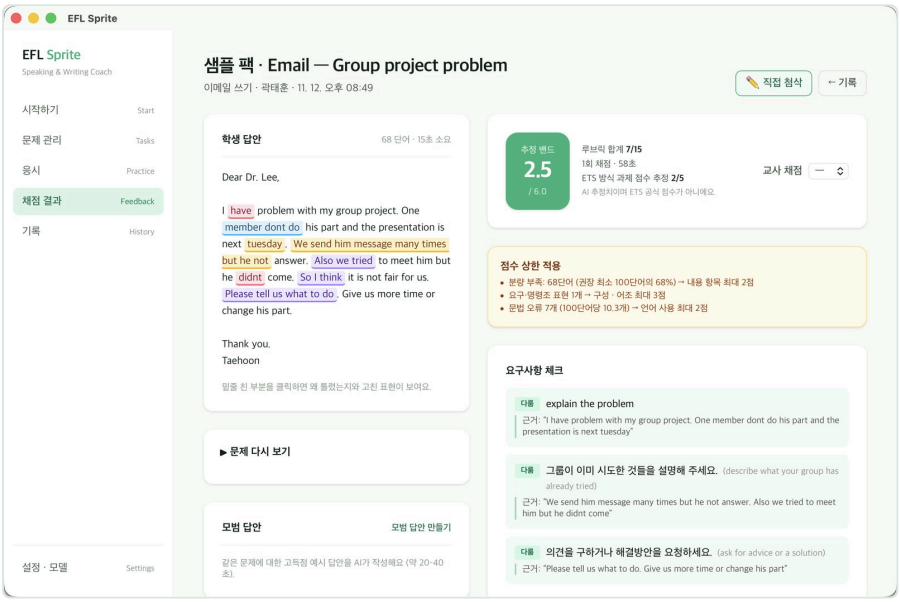


그림 3. 채점 결과(이메일) — 학생 답안의 오류 밑줄, 추정 밴드, 상한 적용 이유, 요구사항 체크(근거 문장 포함)

결과 화면은 점수 상한이 적용된 이유(분량 부족, 명령조 표현, 오류 밀도), 요구사항별 판정과 근거, 항목별 점수와 인용 근거, 언어 지표, 한국어 총평, 교정 목록을 차례로 보여 준다. macOS의 WebView(WKWebView)는 마우스 오버 툴팁을 표시하지 않으므로, 교정 설명은 클릭형 카드로 구현했다.

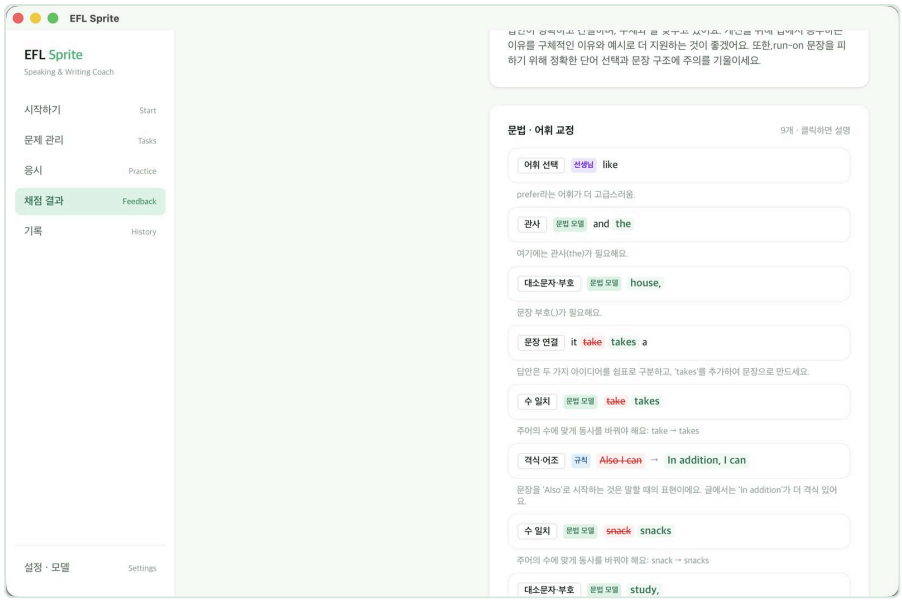


그림 4. 교정 목록 — 교사 첨삭(선생님)이 맨 위에 우선 표시되고, 문법 모델·규칙·AI의 교정이 오류 유형과 이유와 함께 이어짐

5.2 학습자 문법 모델(GECToR)의 Rust 포팅

GECToR는 단어마다 편집 태그(`$KEEP`, `$DELETE`, `$REPLACE_x`, `$APPEND_x`, `$TRANSFORM_VERB_VB_VBZ` 등)를 예측하는 태깅 모델이다. 참고 구현(gotutiyan/gector)의 추론 로직을 Rust로 옮기고 ONNX Runtime(`ort` 크레이트, 동적 로딩)으로 실행했다.

- RoBERTa 토크나이저, `$START` 토큰, 단어별 첫 서브워드 라벨, `$KEEP` 편향, 최소 오류 확률, 최대 3회 반복 교정, 동사 형태 사전
- 모델 출력 텐서를 형태로 판별하고, 실패 시 출력 이름·자료형·형태를 진단 메시지로 제공
- Rust(UTF-8 바이트)와 JavaScript(UTF-16) 문자 위치를 변환해 한글·특수 따옴표가 섞여도 밑줄 위치가 정확
- 합성 ONNX 모델로 통합 테스트를 작성해 실제 모델 없이 *반복 삽입("pay a a a"), 한 단어를 두 번 고쳐 시제가 바뀌는 문제*를 재현하고 수정

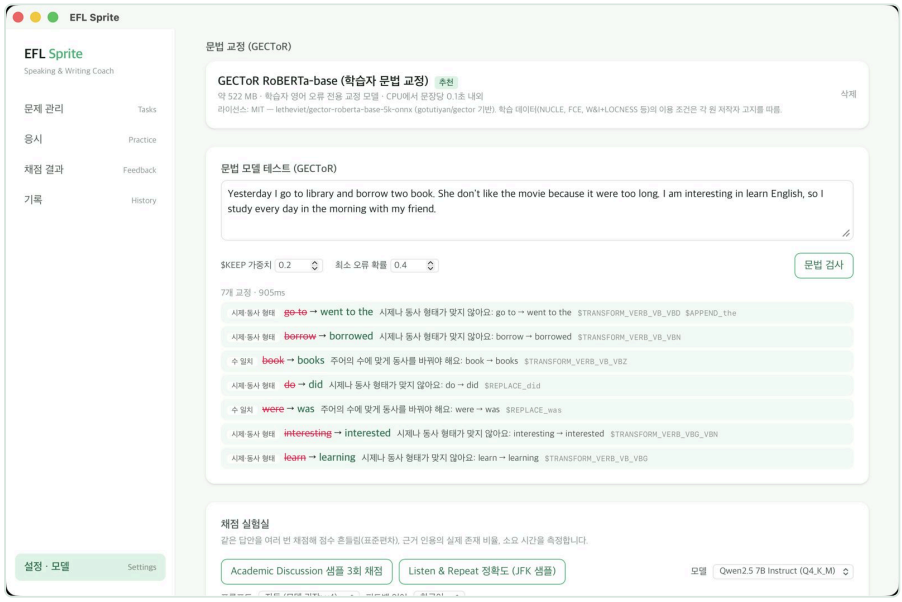


그림 5. 문법 모델 실험 화면 — 의도적으로 넣은 오류 7개를 모두 검출

5.3 자연스러운 한국어 피드백

채점은 영어로 추론하고 결과만 한국어로 번역한다(한국어로 직접 쓰게 하면 판단 품질이 떨어짐, 6.2). 초기 구현에서는 여러 문장을 한 번에 번역하다 출력이 중국어로 무너지고, *the response*를 "반응"으로 직역하는 문제가 있었다. 이를 다음과 같이 해결했다.

- JSON 스키마의 `pattern`으로 **한글 + ASCII만 생성 가능**하도록 문자 집합을 제한(한자·가나 생성 불가)
- 문장 단위 병렬 번역, 용어집(response → 답안), 해요체 예시
- 검증(한자 혼입, 한글 비율, 메타 발화, 예시 복제, 인용어 누락) 후 재시도, 실패 시 영어 원문 표시

5.4 스피킹

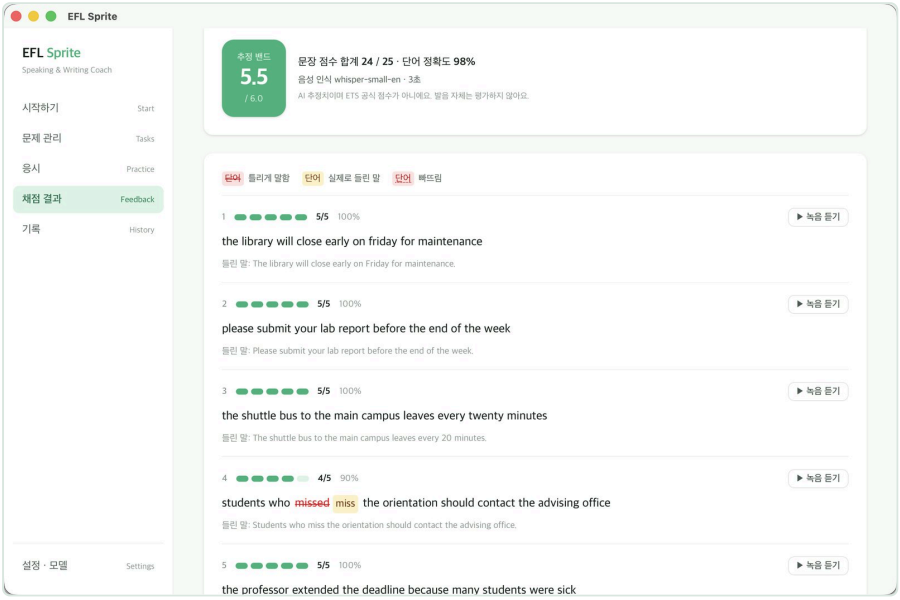


그림 6. Listen and Repeat 결과 — 문장별 점수와 단어 정확도, 원문 대비 틀리게 말한 단어·실제 들린 말, 문장별 녹음 재생

- WebView2(Chromium)와 WKWebView(Safari)의 녹음 포맷 차이를 피하려고 MediaRecorder 대신 원시 샘플을 받아 **16 kHz 모노 WAV로 직접 리샘플·인코딩**하고, 앞뒤 무음을 제거해 Whisper의 환각을 줄였다.
- 문장은 OS 내장 영어 음성(Web Speech API)으로 재생한다. 녹음은 앱 데이터 폴더에 ASCII 파일명으로 저장하고, 재생은 해당 폴더 안 파일만 읽도록 제한했다.
- 따라 말하기는 전사문과 원문의 단어 단위 편집 거리로 정확도를 구해 문장당 0–5점을 매긴다. Whisper는 숫자를 "20"처럼 숫자로 적으므로 비교 전에 0–99를 영어 단어로 바꾼다("twenty-five" ↔ "25"). 인터뷰는 전사문과 말하기 속도(WPM)를 LLM 채점에 넘긴다.
- 마이크를 연 직후에는 OS가 오디오 장치를 전환하느라(블루투스는 통화 모드 전환) 첫 음성의 앞부분이 잘리므로, 0.8초 기다린 뒤 문장을 재생한다. 따라 말하기는 침묵 자동 정지가 연습을 방해해 제거했고, 학생이 "다음"을 누르거나 제한 시간이 끝나면 넘어간다. 말소리가 없는 인터뷰 녹음은 저장하지 않고 다시 녹음하도록 안내한다.

5.5 교사 첨삭과 문제 공유

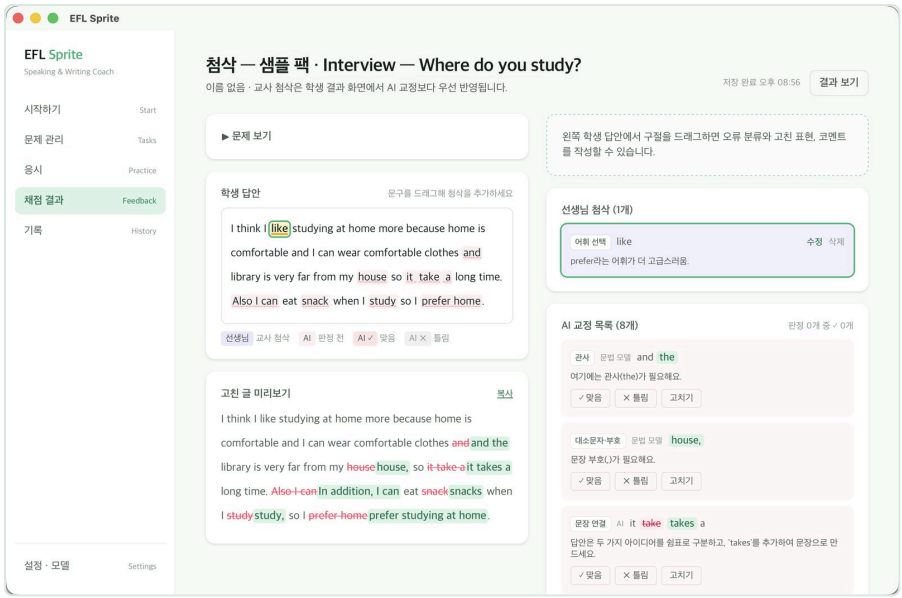


그림 7. 교사 첨삭 화면 — 답안에서 구절을 드래그해 첨삭 작성, AI 교정마다 맞음/틀림/고치기, 고친 글 미리보기

- **교사 첨삭:** 에세이에서 드래그한 구간을 단어 경계에 맞춘 뒤 오류 유형(13개 분류), 고친 표현, 코멘트를 입력한다. AI 교정마다 맞음/틀림/고치기를 기록하고, 학생 화면에서는 교사 첨삭이 겹치는 AI 교정을 대체한다. 맞음/틀림 기록은 AI 교정 정확도 지표가 된다.
- **문제 파일(.eflsprite):** UTF-8 JSON(형식명, 버전, 세트 이름, 작성자, 문제 목록). 가져오기 시 유형·필수 항목·시간을 검증하고 중복을 건너뛴다. 파일 대화상자와 창에 끌어다 놓기를 지원해 카카오톡·USB로 받은 파일을 바로 추가할 수 있다.
- **AI 문제 생성:** 유형별 JSON 스키마(예: 따라 말하기 7문장, 이메일 상황 + 요구사항 3개)로 초안을 만들고, 교사가 수정 후 저장한다.

5.6 크로스플랫폼 처리

문제	처리
Windows 한글 사용자 폴더(`C:\Users\홍길동`)를 C++ 엔진이 ANSI 코드 페이지로 열다 실패	엔진 인자는 데이터 폴더 기준 상대 경로 + ASCII 파일명으로만 전달
엔진 실행 시 콘솔 창 깜빡임	Windows에서 `CREATE_NO_WINDOW`로 자식 프로세스 생성, 앱 종료 시 정리
Windows는 열린 파일을 이름 변경·삭제할 수 없음	다운로드는 `.part`로 받은 뒤 핸들을 닫고 교체, 모델 삭제 전 서버 종료
macOS WebKit은 클릭 직후에만 오디오 시작 허용	오디오 컨텍스트를 클릭 핸들러 안에서 동기적으로 생성, 모든 대기에 시간 제한
모델별 메모리	카탈로그에 모델별 병렬 슬롯·컨텍스트 지정(7B 3×8192, 14B 2×6144)

6. 실험과 평가

모든 실험은 앱의 *채점 실험실*(같은 답안 N회 반복 채점 → 항목별 평균±표준편차, 근거 일치율, 소요 시간)과 *기록* 화면에서 측정했으며, 원자료는 저장소의 `docs/scoring-experiments.md`에 있다. 기준 점수는 현직 TOEFL 강사인 저자의 판단이다.

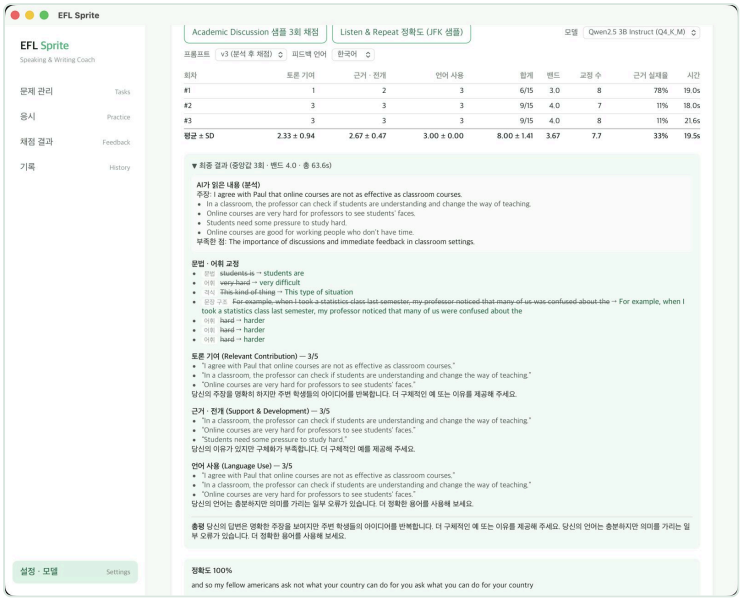


그림 8. 채점 실험실 — 반복 채점의 일관성과 근거 일치율 측정

6.1 기준 답안 (AD-1)

Academic Discussion 답안(약 130단어)에 대한 교사 판단은 **밴드 3.0–3.5**였고, 근거로 7개 항목(*Because*로 시작하는 조각문, *many of us was* 수일치, *so* 대신 *therefore/thus*, 모호한 어휘 *thing·some*, 소유격 누락, 이유의 깊이 부족)을 제시했다.

6.2 프롬프트·구조 변경에 따른 변화

구성	모델	항목 SD(최대)	최종 밴드	근거 일치	관찰
v1 한국어 직접 출력	Qwen2.5-3B	0.94	2.0–2.5	100%	교사보다 1밴드 낮음, 실제 오류 미검출, 코멘트가 틀림
v2 오류 목록 우선 + 별도 번역	Qwen2.5-3B	0.94	3.5	67%	수준은 맞으나 조각문·어조·어휘 미검출
v3 분석 → 채점	Qwen2.5-3B	0.94	4.0	33%	소형 모델 과부하, 잘못된 교정 반복
v3 분석 → 채점	Qwen2.5-7B	0.47	**3.5**	57%	안정적, 근거 부족(인용을 고친 형태로 함)
v3 + 규칙 + 인용 스냅	Qwen2.5-7B	**0.00**	4.0	67→**96%**	교사 지적 5개 항목 모두 검출, 밴드 환산이 후함

v3+규칙 구성에서 항목 점수는 타당했으나 선형 밴드 환산이 후하다는 점이 드러나, 이후 구간별 환산표와 보정 앵커(v4)로 이어졌다. 3개 표본을 llama-server 병렬 슬롯으로 동시에 처리해 전체 시간을 140초에서 93초로 34% 줄였다.

6.3 평가용 답안 세트(ES-1)와 교사–AI 일치도

조정에 쓰지 않은 답안 세트(이메일 2문제 × 2수준, 토론 2문제 × 2수준)를 저자가 앱 결과를 보기 전에 블라인드로 채점했다. 첫 측정에서 55단어 명령조 이메일(교사 1.5)이 4.0을 받는 등 이메일이 과대평가되었고, 요구사항 개별 판정·어조 상한·오류 밀도 상한·환산표 조정 후 다시 측정했다.

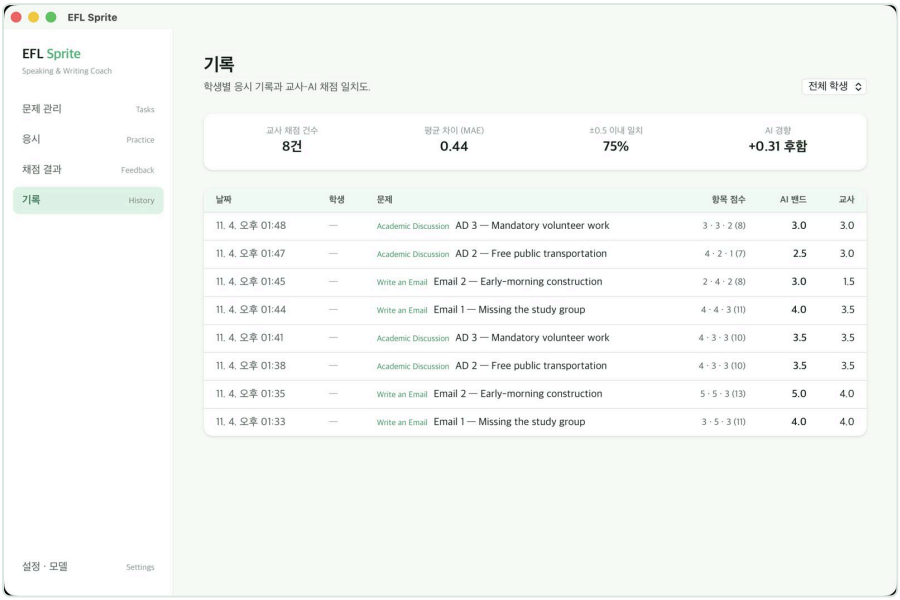


그림 9. 기록 화면 — 교사 점수 8건 기준 MAE 0.44, ±0.5 이내 75%, 항목 점수 표시

지표	값	해석
평균 절대 오차(MAE)	0.44 밴드	밴드 단위(0.5)보다 작은 평균 차이
±0.5 밴드 이내 일치	75% (6/8)	Academic Discussion 4건은 모두 정확히 일치(조정 전 측정)
경향(AI–교사)	+0.31	여전히 약간 후함. 차이는 주로 저수준 이메일
과대평가 사례	4.0 → 2.5	교사 1.5. ETS 기술(2–3/5 수준)과 비교해 추가 조정은 보류

6.4 교정의 정확도



그림 10. 개선 전 — 거의 오류가 없는 답안에 LLM이 만든 잘못된 교정(수일치·조각문)이 표시된 상태

거의 오류가 없는 Academic Discussion 답안에서 문법 모델은 0건을 보고했지만 LLM은 4건의 잘못된 교정을 냈다. 긴 채점 프롬프트 안에서 "오류를 찾으라"고 요구하면 소형 LLM은 오류가 없어도 만들어 낸다. 문법 범주를 문법 모델·규칙에만 맡기고 LLM 제안은 별도 호출(문장 전체 제시, 이유 → 판정)로 재검증하도록 바꿔, 같은 유형의 가짜 교정이 표시되지 않게 했다. 학습자 오류가 많은 답안에서는 문법 모델과 어조 규칙이 주요 오류를 그대로 검출했다. 문법 모델은 의도적으로 넣은 오류 7개를 모두 검출했고(잘못된 교정 0건, 모델 로딩 포함 0.9초), 이후 교사 첨삭 화면의 맞음/틀림 기록으로 AI 교정 정확도를 지속적으로 측정할 수 있게 했다.

6.5 평가의 한계

- 교사 점수는 ETS 공식 기준이 아닌 강사 1인의 종합 판단이며 표본이 8건이다. 결과는 "현직 강사 판단과의 일치도"로 한정한다.
- ES-1 답안은 저자가 정한 수준·오류 유형에 맞춰 AI 도구로 초안을 작성했다. 실제 학생 답안 분포와 다를 수 있다.
- 최종 검증은 조정에 쓰지 않은 새 답안을 ETS 기술 기준표로 채점하고, 가능하면 강사 2인의 사람 간 일치도와 비교한다.

7. 배포와 품질 관리

7.1 Microsoft Store 배포

항목	내용
스토어 주소	https://apps.microsoft.com/detail/9MZT0SB40M2W (무료, 교육 카테고리, IARC 3+)
패키지 형식	MSIX. EXE/MSI 설치 파일 제출은 유료 코드 서명 인증서가 필요하지만, MSIX는 심사 후 Microsoft가 서명한다.

패키지 ID	`TaehoonKwack.EFLSprite` (Partner Center 발급), Store ID 9MZT0SB40M2W
권한	`runFullTrust`(포함된 추론 엔진 실행), `microphone`(스피킹)
패키징	릴리스 빌드 → 스크립트가 실행 파일·엔진·스토어 아이콘·매니페스트를 배치 → `makeappx`로 패키지, 테스트용 자체 서명본과 인증서 동시 생성
크기	약 57 MB (AI 모델은 첫 실행 때 앱 안에서 내려받음)
정책 대응	개인정보처리방침 공개, 심사관용 테스트 절차·권한 사유 작성, 제품명에 상표 미사용 및 상표 고지
심사 경과	11/8 제출 → 1차 반려(정책 10.1.1.3 부정확한 표현: 스크린샷에 macOS 창 테두리가 보임. 패키지·권한은 통과) → 운영체제와 무관한 앱 화면만 남기도록 스크린샷 수정 후 재제출 → 11/9 게시
업데이트	v0.1.1(11/12): 화면 참조 작성, 실기기 테스트에서 찾은 문제 수정(7.3), 백엔드 일부 개선을 반영한 패키지를 GitHub Actions에서 빌드해 Partner Center에 업데이트로 제출

7.2 지속적 통합

- GitHub Actions에서 **모든 푸시마다 macOS(Apple Silicon)·Windows 동시 빌드**, Windows 작업은 스토어용 MSIX까지 생성한다. 버전 태그를 올리면 실행 파일이 GitHub Release에 게시된다.
- 엔진(llama.cpp, whisper.cpp, ONNX Runtime)은 버전을 고정해 받아 캐시하고, 받은 직후 실행 확인(smoke test)을 한다.
- Rust 단위 테스트 17개(DB 마이그레이션, 기록, 오디오 저장과 경로 검사(`..` 우회 차단 포함), 문제 파일, 저장 경로, GECToR 태그 적용·편집 추출 등)와 합성 모델 통합 테스트 1개.
- 화면 참조 작성은 별도 브랜치에서 진행하고, Pull Request로 두 운영체제 빌드가 통과한 뒤 main에 병합했다(작성자 구분을 보존하는 merge commit).

7.3 실기기 테스트에서 발견해 고친 문제

증상	원인 → 조치
macOS 동적 라이브러리를 찾지 못함	심볼릭 링크가 복사 후 깨짐 → 실제 파일로 복사, 정리 후 실행 확인
모델 중복 다운로드 시 파일 오류	동시 요청 → 진행 중 다운로드 중복 방지
스피킹 "시작"이 반응 없음	WebKit 오디오 시작 규칙, 개발 모드의 화면 재마운트 시 상태 초기화 누락 → 동기 생성, 상태 재설정, 시간 제한
교정 밑줄이 엉뚱한 단어에 표시	모델 인용이 교정문보다 짧음 → 정렬 비용이 최소인 범위로 확장
문제 삭제 시 기록이 경고 없이 삭제	CASCADE 삭제 → 함께 지워지는 기록 수를 보여 주고 확인
따라 말하기에서 "twenty"를 맞게 말해도 감점(4/5)	Whisper가 "20"으로 받아 적음, 숫자 변환표가 0–12뿐 → 0–99 변환(두 단어 숫자 포함), 재채점 5/5
시작 직후 첫 문장 음성의 앞부분이 잘림	마이크를 열 때 OS 오디오 장치 전환 → 마이크를 연 뒤 0.8초 대기

따라 말하기 중 잠깐 멈추면 녹음이 끊김	1.5초 침묵 자동 정지 → 연습 흐름에 맞게 제거, "다음" 버튼과 제한 시간으로 진행
"eat snack → snacks"를 동사 수 일치로 설명	문법 모델이 명사 복수에도 동사 변형 태그를 씀 → 앞 단어가 소유격·전치사·타동사면 복수형으로 분류
요구사항 상태 배지 "다룸"이 두 줄로 쪼개짐	긴 문장 옆에서 배지가 줄어들고 한국어는 글자 사이에서 줄바꿈 → 배지 크기 고정

8. 개발 과정과 역할 분담

개발은 "요구사항·기준 정의 → 구현 → 실기기 실행과 채점 비교 → 문제 발견과 개선 방향 제시"를 하루 단위로 반복했다. 구현에는 AI 코딩 도구(Anthropic Claude Code)를 활용했다. 초기 버전은 AI 도구가 전체 코드를 작성하였고, 이후 저자가 화면(프론트엔드) 코드를 **참조 작성**하였다. 여기서 참조 작성이란, AI 도구가 만든 초기 버전을 참조하여 구조와 동작을 이해한 뒤 직접 다시 작성한 것을 말한다. 최종 코드 기준 역할 분담은 다음과 같다.

영역	담당	내용
화면 (프론트엔드)	저자 (참조 작성)	학생·교사가 쓰는 모든 화면(응시, 녹음, 채점 결과, 교사 첨삭, 문제 관리·공유, 기록, 설정, 문법 모델 실험). 채점 실험실(측정 도구)만 AI 작성본 유지
엔진·모델·채점 로직 (백엔드)	AI 도구	추론 엔진 실행·관리, 문법 모델(GECToR) 포팅, 채점 파이프라인, 데이터베이스
백엔드 일부	저자 (참조 작성)	문제 파일, 저장 경로, 녹음 파일 처리(`taskfile.rs`, `paths.rs`, `audio.rs`), 따라 말하기 숫자 정규화, 문법 모델 오류 분류 보정
기획·채점 기준·검증·배포	저자	현장 문제 정의, 4개 유형 선정, 기준 답안 채점과 오류 지적, 블라인드 채점, 프롬프트 실험 방향 결정, 실기기 테스트, Microsoft Store 등록·심사 대응

엔진·모델·채점 로직을 AI 도구로 작성한 이유.

1. **학부 과정에서 다루지 않은 기술:** 음성 인식(whisper.cpp)과 언어 모델(llama.cpp)을 외부 프로세스로 실행·관리하는 코드, 문법 교정 논문 모델(GECToR)을 ONNX Runtime으로 옮기는 작업은 학부 교과 범위를 넘어선다. 정확성과 안정성을 위해 이 부분은 AI 도구의 구현을 사용하고, 저자는 동작 검증과 결과 판단에 집중하였다.
2. **운영체제 호환성:** Windows(한글 사용자 폴더, 콘솔 창 숨김, 열린 파일 처리)와 macOS의 차이를 다루는 저수준 처리는 전문 지식이 필요하다.
3. **측정 결과의 일관성:** 6장의 채점 일관성(SD)과 교사 일치도는 현재 채점 로직과 채점 실험실로 측정하였다. 이 코드를 다시 작성하면 측정을 처음부터 반복해야 하므로 그대로 유지하였다.

참조 작성 과정에서는 초기 버전의 버그(모델 다운로드 실패 후 화면이 멈춤, 문장을 고친 뒤 예전 위치로 교정을 표시, 모범 답안이 예전 채점 기록에 저장, macOS에서 보이지 않는 툴팁 등)를 함께 고쳤고, 교사가 3.0으로 채점한 답안을 다시 채점해 같은 3.0이 나오는 것으로 채점 결과가 바뀌지 않았음을 확인했다. 참조 작성 이후 AI 도구로 수정한 부분은 두 커밋(교정 목록 배지 크기 조정, 녹음 화면 버그 3건)이다.

8.1 저자의 판단이 설계를 바꾼 사례

저자가 발견한 문제	바뀐 설계	결과
AI가 조각문·수일치·*so*·모호 어휘를 놓침	결정적 규칙 검사, 인용 스냅	5개 항목 검출
점수가 전반적으로 후함 (55단어 이메일 4.0)	보정 앵커, 상한, 구간별 환산표	4.0 → 2.5
마우스 오버로는 고친 표현이 안 보이고 이유가 없음	클릭형 교정 카드, 오류 분류와 원칙	교정마다 이유
전문 문법 모델이 필요함	GECToR 도입(Rust 포팅)	7/7 검출
피드백 한국어가 부자연스러움(반응, 한자)	문자 집합 제약, 문장 단위 번역, 검증	깨진 번역 차단
요구사항을 썼는데도 빠졌다고 판정	요구사항별 개별 판정(인용 → 판정)	판정 근거 표시
맞는 문장에 엉뚱한 문법 교정	정확도 우선 구조, LLM 교정 재검증	가짜 교정 제거
교사 점수는 ETS 기준이 아닌 주관 판단	평가 주장 범위 재정의, 최종 검증 계획	정직한 보고
학생이 문제를 일일이 입력하기 어려움, 교사가 AI를 바로잡아야 함	AI 문제 생성, 파일 공유, 교사 첨삭	학원 운영 흐름

AI 활용 명시. 개발 도구로 Anthropic Claude Code를 코드 작성, 문서 초안, 기술 조사에 사용했다. 커밋 기록의 `Co-Authored-By: Claude` 표시는 AI 도구가 참여한 커밋을 뜻하며, 화면 참조 작성 커밋은 저자 단독 커밋으로 남아 있다. 평가용 답안(ES-1)은 저자가 정한 수준에 맞춰 AI 도구로 초안을 작성한 뒤 저자가 블라인드로 채점했다. 앱 안의 AI 모델(Whisper, Qwen, GECToR)은 제품 구성 요소로 개발 도구와 별개이다. 모든 결과물은 저자가 실행·검토했으며 책임은 저자에게 있다.

9. 결론과 향후 과제

9.1 결론

EFL Sprite는 학생 데이터를 기기 밖으로 내보내지 않으면서 TOEFL iBT 2026 형식의 말하기·쓰기 연습에 근거 있는 피드백을 주는 데스크톱 앱이다. 단일 LLM에 채점을 맡겼을 때 나타난 불안정성(반복 채점 표준편차 0.94), 과대평가, 가짜 교정, 깨진 한국어 피드백을 **역할 분담 구조 · 출력 형식 강제 · 측정 지표 · 다단계 검증**으로 해결했고, 현직 강사 판단과 평균 0.44밴드 차이를 보였다. 교사 첨삭과 문제 공유 기능으로 AI를 강사를 대체하는 도구가 아닌 **강사의 검토를 돕는 도구**로 자리매김했으며, 두 운영체제 자동 빌드와 MSIX 패키징으로 실제 스토어 배포까지 진행했다.

9.2 한계

- 발음은 평가하지 않는다. 스피킹은 음성 인식 결과(내용·유창성 지표)로만 채점한다.
- 음성 인식이 학습자의 틀린 발화를 고쳐서 받아 적을 수 있어 따라 말하기 정확도가 과대 추정될 수 있다.
- 교사 점수 표본(8건)이 적어 환산표와 지표 기준값은 임시값이다.
- 채점 시간은 PC 성능에 좌우된다(Apple Silicon 7B 기준 1회 40–70초).

9.3 향후 과제

- 새 답안과 ETS 기술 기준표, 강사 2인 채점으로 최종 검증하고 사람 간 일치도와 비교
- 교사 첨삭의 맞음/틀림 데이터로 교정 규칙과 환산표를 자동 보정
- 발음 평가 모델 연동, 실제 학생 답안 데이터 수집(동의 기반)

부록

A. 설치와 실행

대상	방법
Windows (일반)	Microsoft Store에서 "EFL Sprite" 설치, 또는 GitHub Release의 설치 파일 실행
macOS (Apple Silicon)	GitHub Release의 앱 압축 파일 → 응용 프로그램 폴더 → 우클릭 → 열기
개발 환경	`npm install` → `npm run fetch-engines` → `npm run tauri dev`
첫 실행	시작하기 → 추천 모델 받기(약 5 GB) → 예시 문제 추가 → 응시

B. 저장소 구조

경로	내용
`src/`	React UI — 페이지, 피드백·녹음·첨삭 컴포넌트, 채점 파이프라인(`src/lib`)
`src-tauri/src/`	Rust 백엔드 — 경로, DB, 모델 다운로드, 오디오, 문제 파일, 엔진(`engine/`)
`src-tauri/msix/`, `scripts/`	스토어 매니페스트·패키지 ID, 엔진 다운로드·MSIX 패키징 스크립트
`docs/`	개발 가이드, 개발 과정 기록, 채점 실험 기록, 평가 답안 세트, 개인정보처리방침, 스토어 등록 정보, 시연 대본, 보고서 원본(`report-source/`)
`EFL-Sprite_결과보고서.pdf`	본 보고서 (저장소 최상위)
`samples/`	예시 문제 파일(`.eflsprite`)

C. 사용한 오픈소스와 모델

Tauri (MIT/Apache-2.0) · llama.cpp (MIT) · whisper.cpp (MIT) · ONNX Runtime (MIT) · OpenAI Whisper 모델 (MIT) · Qwen2.5-7B/14B-Instruct (Apache-2.0) · GECToR RoBERTa-base 5k ONNX — letheviet/gector-roberta-base-5k-onnx, gotutiyan/gector 기반 (MIT)

D. 참고 자료

1. ETS, TOEFL iBT Writing scoring guides (Write an Email / Academic Discussion).
2. Omelianchuk et al., "GECToR – Grammatical Error Correction: Tag, Not Rewrite," BEA Workshop, 2020.
3. Attali & Burstein, "Automated Essay Scoring with e-rater V.2," Journal of Technology, Learning, and Assessment, 2006.
4. Covington & McFall, "Cutting the Gordian Knot: The Moving-Average Type–Token Ratio (MATTR)," Journal of Quantitative Linguistics, 2010.
5. Radford et al., "Robust Speech Recognition via Large-Scale Weak Supervision" (Whisper), 2022.
6. Qwen Team, "Qwen2.5 Technical Report," 2024.

TOEFL은 ETS의 등록 상표이며, EFL Sprite는 ETS와 관련이 없고 ETS의 승인을 받지 않았습니다. 앱의 점수는 AI 추정치로 공식 점수가 아닙니다.